Dokumentáció

Előzmények, eredeti háló, felmerült problémák:

Az előző félév során Az Önálló kutatási Feladat 1 nevű tárgy keretein belül készítenünk kellett egy projektfeladatot, amely során a következőt választottam:

- a témám a következő volt: Áttétes nyirokcsomó daganatok meghatározása szövettani képek osztályozásával neurális hálókat alkalmazva
- megoldás: egy saját CNN építése a képek osztályozására

A megoldás során több problémám merült fel, nem sikerült a legjobban a háló felépítése, mert körülbelül csak 75%-os pontossággal osztályozott jól, valamint az adat mennyisége miatt memóriahiányom lépett fel.
Régi modell:

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d (Conv2D)              (None, 46, 46, 16)        448
_________________________________________________________________
max_pooling2d (MaxPooling2D) (None, 23, 23, 16)        0
_________________________________________________________________
conv2d_1 (Conv2D)            (None, 21, 21, 32)        4640
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 (None, 10, 10, 32)        0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 8, 8, 64)          18496
_________________________________________________________________
max_pooling2d_2 (MaxPooling2 (None, 4, 4, 64)          0
_________________________________________________________________
conv2d_3 (Conv2D)            (None, 2, 2, 64)          36928
_________________________________________________________________
max_pooling2d_3 (MaxPooling2 (None, 1, 1, 64)          0
_________________________________________________________________
flatten (Flatten)            (None, 64)                0
_________________________________________________________________
dense (Dense)                (None, 512)               33280
_________________________________________________________________
dense_1 (Dense)              (None, 1)                 513
=================================================================
Total params: 94,305
Trainable params: 94,305
Non-trainable params: 0
```

Feladatok:

Az előzetes egyeztetések során, meg kellett próbálnom csökkenteni a futási időn, új modellt implementálni, batch normalizációt alkalmazni, valamint egy adatbetöltőt függvényt alkalmazni.

Megvalósítások:

A már meglévő CNN-be építettem be batch normalizációs rétegeket, hogy megnézzük ez javít-e a predikció pontosságán.

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d_25 (Conv2D)           (None, 94, 94, 16)        448
_________________________________________________________________
batch_normalization_5 (Batch (None, 94, 94, 16)        64
_________________________________________________________________
max_pooling2d_25 (MaxPooling (None, 47, 47, 16)        0
_________________________________________________________________
conv2d_26 (Conv2D)           (None, 45, 45, 32)        4640
_________________________________________________________________
batch_normalization_6 (Batch (None, 45, 45, 32)        128
_________________________________________________________________
max_pooling2d_26 (MaxPooling (None, 22, 22, 32)        0
_________________________________________________________________
conv2d_27 (Conv2D)           (None, 20, 20, 32)        9248
_________________________________________________________________
batch_normalization_7 (Batch (None, 20, 20, 32)        128
_________________________________________________________________
max_pooling2d_27 (MaxPooling (None, 10, 10, 32)        0
_________________________________________________________________
conv2d_28 (Conv2D)           (None, 8, 8, 64)          18496
_________________________________________________________________
batch_normalization_8 (Batch (None, 8, 8, 64)          256
_________________________________________________________________
max_pooling2d_28 (MaxPooling (None, 4, 4, 64)          0
_________________________________________________________________
conv2d_29 (Conv2D)           (None, 2, 2, 64)          36928
_________________________________________________________________
batch_normalization_9 (Batch (None, 2, 2, 64)          256
_________________________________________________________________
max_pooling2d_29 (MaxPooling (None, 1, 1, 64)          0
_________________________________________________________________
flatten_5 (Flatten)          (None, 64)                0
_________________________________________________________________
dense_11 (Dense)             (None, 512)               33280
_________________________________________________________________
dense_12 (Dense)             (None, 1)                 513
=================================================================
Total params: 104,385
Trainable params: 103,969
Non-trainable params: 416
```

A modellek tanulás során az epoch-ok pontossága a normalizációs rétegekkel javult viszont maga a végeredményen nem sikerült javulást elérnem.
Normalizációs rétegek nélkül:

```
9/9 [==============================] - 1s 165ms/step - loss: 0.6748 - accuracy: 0.6000
0.6000000238418579
```

Normalizációs rétegekkel:

```
9/9 [==============================] - 2s 176ms/step - loss: 1.5332 - accuracy: 0.5200
0.5199999809265137
```

Normalizációs rétegek nélkül:

```
Epoch 1/20
26/26 [==============================] - 15s 559ms/step - loss: 0.6832 - accuracy: 0.5818
Epoch 2/20
26/26 [==============================] - 13s 505ms/step - loss: 0.6763 - accuracy: 0.5939
Epoch 3/20
26/26 [==============================] - 13s 513ms/step - loss: 0.6765 - accuracy: 0.5939
Epoch 4/20
26/26 [==============================] - 13s 504ms/step - loss: 0.6762 - accuracy: 0.5939
Epoch 5/20
26/26 [==============================] - 13s 515ms/step - loss: 0.6759 - accuracy: 0.5939
Epoch 6/20
26/26 [==============================] - 13s 504ms/step - loss: 0.6763 - accuracy: 0.5939
Epoch 7/20
26/26 [==============================] - 13s 506ms/step - loss: 0.6754 - accuracy: 0.5939
Epoch 8/20
26/26 [==============================] - 13s 505ms/step - loss: 0.6761 - accuracy: 0.5939
Epoch 9/20
26/26 [==============================] - 13s 495ms/step - loss: 0.6758 - accuracy: 0.5939
Epoch 10/20
26/26 [==============================] - 13s 497ms/step - loss: 0.6765 - accuracy: 0.5939
Epoch 11/20
26/26 [==============================] - 13s 505ms/step - loss: 0.6756 - accuracy: 0.5939
Epoch 12/20
26/26 [==============================] - 13s 509ms/step - loss: 0.6756 - accuracy: 0.5939
Epoch 13/20
26/26 [==============================] - 13s 508ms/step - loss: 0.6756 - accuracy: 0.5939
Epoch 14/20
26/26 [==============================] - 14s 521ms/step - loss: 0.6759 - accuracy: 0.5939
Epoch 15/20
26/26 [==============================] - 13s 508ms/step - loss: 0.6755 - accuracy: 0.5939
Epoch 16/20
26/26 [==============================] - 13s 511ms/step - loss: 0.6751 - accuracy: 0.5939
Epoch 17/20
26/26 [==============================] - 13s 498ms/step - loss: 0.6749 - accuracy: 0.5939
Epoch 18/20
26/26 [==============================] - 13s 511ms/step - loss: 0.6751 - accuracy: 0.5939
Epoch 19/20
26/26 [==============================] - 13s 510ms/step - loss: 0.6744 - accuracy: 0.5939
Epoch 20/20
26/26 [==============================] - 13s 511ms/step - loss: 0.6735 - accuracy: 0.5939
```

Normalizációs rétegekkel:

```
Epoch 1/20
26/26 [==============================] - 30s 1s/step - loss: 0.7118 - accuracy: 0.5515
Epoch 2/20
26/26 [==============================] - 29s 1s/step - loss: 0.6596 - accuracy: 0.6036
Epoch 3/20
26/26 [==============================] - 29s 1s/step - loss: 0.6205 - accuracy: 0.6679
Epoch 4/20
26/26 [==============================] - 29s 1s/step - loss: 0.5701 - accuracy: 0.7030
Epoch 5/20
26/26 [==============================] - 29s 1s/step - loss: 0.4769 - accuracy: 0.7776
Epoch 6/20
26/26 [==============================] - 30s 1s/step - loss: 0.3668 - accuracy: 0.8442
Epoch 7/20
26/26 [==============================] - 31s 1s/step - loss: 0.3181 - accuracy: 0.8515
Epoch 8/20
26/26 [==============================] - 29s 1s/step - loss: 0.2098 - accuracy: 0.9091
Epoch 9/20
26/26 [==============================] - 27s 1s/step - loss: 0.1487 - accuracy: 0.9418
Epoch 10/20
26/26 [==============================] - 27s 1s/step - loss: 0.1376 - accuracy: 0.9485
Epoch 11/20
26/26 [==============================] - 27s 1s/step - loss: 0.1601 - accuracy: 0.9382
Epoch 12/20
26/26 [==============================] - 27s 1s/step - loss: 0.1334 - accuracy: 0.9424
Epoch 13/20
26/26 [==============================] - 27s 1s/step - loss: 0.1046 - accuracy: 0.9600
Epoch 14/20
26/26 [==============================] - 28s 1s/step - loss: 0.0955 - accuracy: 0.9618
Epoch 15/20
26/26 [==============================] - 27s 1s/step - loss: 0.0490 - accuracy: 0.9818
Epoch 16/20
26/26 [==============================] - 27s 1s/step - loss: 0.0443 - accuracy: 0.9848
Epoch 17/20
26/26 [==============================] - 27s 1s/step - loss: 0.0459 - accuracy: 0.9842
Epoch 18/20
26/26 [==============================] - 27s 1s/step - loss: 0.0694 - accuracy: 0.9721
Epoch 19/20
26/26 [==============================] - 27s 1s/step - loss: 0.1241 - accuracy: 0.9479
Epoch 20/20
26/26 [==============================] - 28s 1s/step - loss: 0.1427 - accuracy: 0.9406
```

Sikerült megoldanom a képek beolvasását, hogy egyszerre csak egy részüket tartsa a memóriában, ám ehhez egy külön kóddal kellett rendszereznem az adathalmazomat, az alábbi módon:

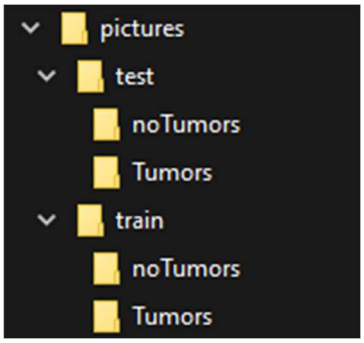

Ekkor már tudtam alkalmazni a Python beépített képbetöltő függvényét, az ImageDataGeneratort().

A futási időn sajnos nem sikerült csökkentenem, így a sok tesztelgetés során nem futtattam az egész adathalmazon, hanem csak kisebb részletein, hogy lássam a kód tényleges működését.

Megpróbáltam új modellt implementálni, de az új adatbetöltő alkalmazása mellett mindez nem sikerült. Első sorban a ResNet50-el és a VGG16-al próbálkoztam.

Hivatkozások:

- https://www.kaggle.com/omniscientist99/metastatic-cancer-in-lymph-nodes-fastai-resnet50
- https://github.com/Precillieo/Elixir-Cancer-Diagnosis-AI-Based-System/blob/main/Elixir/Cancer-Prediction.ipynb
- https://machinelearningmastery.com/how-to-load-large-datasets-from-directories-for-deep-learning-with-keras/
- https://machinelearningmastery.com/how-to-develop-a-convolutional-neural-network-to-classify-photos-of-dogs-and-cats/
- https://keras.io/api/applications/

2021. május 28.

Kubicza Gréta Andrea
IU5Y7G